

Regressão Linear: Probabilidade vs. Otimização

Uma dedução dos pressupostos sobre os erros

Luca WB

2026-08-09

Table of contents

1	Breve introdução	3
2	Dedução via Otimização	4
2.1	O Truque de Notação (Notation Trick)	4
2.2	Expandindo a Equação Algébrica	5
2.3	A Derivada Matricial (Calculando o Gradiente)	5
2.4	Minimização e a Equação Normal	6
3	Dedução via Probabilidade/Esperança	7
3.1	O pressuposto fundamental	7
3.2	Por que assumir $E[u X] = 0$?	8
3.3	Ortogonalidade entre erro e variáveis explicativas	8
3.4	Da população para a amostra	9
4	Comparando as duas deduções	10

1 Breve introdução

Esse post surgiu por conta da minha primeira aula da cadeira de Aprendizado Profundo na universidade, nessa aula, o professor fez a demonstração da formula normal da regressão linear. Não era exatamente uma novidade essa formula, eu já sabia demonstrar essa formula de cabeça usando valor esperado condicional, o que me intrigou foi um detalhe da demonstração. Meu professor usou a abordagem de otimização para dedução, calculando o ponto minimo global da função perda/avaliação. Isso me intrigou pelo fato de que, a primeira vista, não tínhamos levantado nenhum pressuposto sobre a natureza do erro do nosso modelo, coisa que temos que fazer para realiar a dedução via valor esperado.

Assim, gastei meu fim de semana seguinte pensando sobre o assunto, pesquisei um pouco na internet sobre a correlção entre as duas abordagens e os pressupostos dela, e não achei nada muito satisfatório, então comecei a rabiscar no papel para ver se esclarecia alguma coisa, e acredito ter achado uma perspectiva interessante para ver a relação entre as duas abordagens no que tange os pressupostos sobre o erro

2 Dedução via Otimização

Primeiro, antes de mais nada, é preciso estar familiarizado sobre as deduções, para que então possamos falar sobre elas.

A ideia central na regressão linear é encontrar os parâmetros (ou pesos) que minimizam o erro das nossas previsões. Assim como no exemplo do gradiente onde olhamos para a derivada para encontrar a direção que reduz o valor da função, aqui o nosso objetivo principal é minimizar a função de custo conhecida como Soma dos Erros Quadráticos (SSE - *Sum of Squared Errors*).

A fórmula clássica do SSE é a soma das diferenças ao quadrado entre o valor real (y_i) e o valor previsto ($\hat{y}_i$):

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

2.1 O Truque de Notação (Notation Trick)

Antes de derivarmos, precisamos simplificar nossa notação. Um modelo linear comum tem um viés (intercepto ou *bias*) b e os pesos das características $w_1, \dots, w_m$. A previsão para uma única amostra é escrita como:

$$\hat{y}_i = b + w_1 x_{i1} + \dots + w_m x_{im}$$

Para evitar o trabalho de calcular as derivadas do viés b separadamente dos outros pesos, nós usamos um **truque de notação** (*notation trick*). Nós incorporamos o b no vetor de pesos w (sendo o primeiro elemento, w_0) e adicionamos uma coluna inteira de 1s na nossa matriz de características X .

Dessa forma, a previsão de todas as amostras ao mesmo tempo se transforma em uma elegante multiplicação de matrizes:

$$\hat{y} = Xw$$

Com esse truque, a nossa função de erro SSE pode ser reescrita na sua forma vetorializada:

$$SSE(w) = (y - Xw)^T (y - Xw)$$

2.2 Expandindo a Equação Algébrica

Para conseguir derivar a função e encontrar o ponto de mínimo, vamos primeiro expandir a multiplicação dessas matrizes:

$$\begin{aligned}SSE(w) &= (y^T - (Xw)^T)(y - Xw) \\SSE(w) &= y^T y - y^T Xw - (Xw)^T y + (Xw)^T (Xw)\end{aligned}$$

Aplicando a propriedade da matriz transposta, onde $(AB)^T = B^T A^T$:

$$SSE(w) = y^T y - y^T Xw - w^T X^T y + w^T X^T Xw$$

Aqui entra um detalhe geométrico e algébrico importante, se você observar as dimensões, o termo $y^T Xw$ resulta em um único número, ou seja, é um **escalar**. Como a transposta de um escalar é ele mesmo, podemos dizer que $(y^T Xw)^T = w^T X^T y$. Portanto, os dois termos do meio são idênticos e podemos agrupá-los:

$$SSE(w) = y^T y - 2w^T X^T y + w^T X^T Xw$$

2.3 A Derivada Matricial (Calculando o Gradiente)

A ideia básica é que, se queremos minimizar o valor da função, precisamos olhar para a derivada dela. Como SSE é uma função convexa, o seu ponto de mínimo global ocorre exatamente onde a inclinação (o gradiente) é zero. Vamos derivar a função em relação ao vetor de pesos w :

$$\frac{\partial}{\partial w} SSE(w) = \frac{\partial}{\partial w} (y^T y - 2w^T X^T y + w^T X^T Xw)$$

Analisando termo a termo:

1. A derivada de $y^T y$ em relação a w é 0 (pois é apenas uma constante, não depende de w).
2. Usando a regra de derivada matricial $\frac{\partial}{\partial w} (w^T a) = a$, a derivada de $-2w^T X^T y$ é $-2X^T y$.
3. Para formas quadráticas, a regra é $\frac{\partial}{\partial w} (w^T A w) = 2Aw$. Logo, a derivada de $w^T X^T Xw$ é $2X^T Xw$.

Juntando todas as peças, o nosso gradiente é:

$$\frac{\partial}{\partial w} SSE(w) = -2X^T y + 2X^T Xw$$

2.4 Minimização e a Equação Normal

Agora, basta aplicar a ideia fundamental da otimização: igualar o gradiente a zero para encontrar o fundo do “vale” da função de custo.

$$\begin{aligned}0 &= -2X^T y + 2X^T X w \\2X^T X w &= 2X^T y\end{aligned}$$

Dividindo os dois lados por 2, temos:

$$X^T X w = X^T y$$

Finalmente, para isolar o nosso vetor de pesos ótimos w , multiplicamos ambos os lados da equação pela inversa da matriz $(X^T X)$:

$$w = (X^T X)^{-1} X^T y$$

E esta é a **Equação Normal** da regressão linear. Ela nos dá, de forma direta e analítica, os pesos exatos que minimizam o erro.

3 Dedução via Probabilidade/Esperança

Na seção anterior obtivemos a Equação Normal resolvendo um problema de otimização. Agora vamos chegar ao mesmo resultado partindo de uma interpretação probabilística do modelo linear.

3.1 O pressuposto fundamental

Considere o modelo

$$y = Xw + u,$$

onde u é nosso erro, isto é, representa tudo aquilo que não está sendo explicado pelas variáveis observadas em X (Já estamos usando o notation trick e notação matricial). Por definição do nosso modelo $u = y - Xw$

A hipótese mais importante é que iremos assumir, é:

$$\boxed{E[u \mid X] = 0}.$$

Em palavras:

Depois de observarmos os valores de X , o erro continua tendo média zero.

Essa hipótese é mais forte do que simplesmente assumir

$$E[u] = 0.$$

De fato,

$$E[u \mid X] = 0 \implies E[u] = 0,$$

mas a recíproca não é verdadeira.

3.2 Por que assumir $E[u \mid X] = 0$?

A ideia é que toda a estrutura sistemática explicável por X já foi incorporada ao termo Xw .

Se a média do erro ainda dependesse de X , então existiria informação em X que o modelo não está utilizando.

Por exemplo, suponha que

$$E[u \mid X = x] = x^2.$$

Nesse caso, conhecer x permite prever o erro em média, indicando que o modelo ainda está omitindo uma relação importante.

A condição

$$E[u \mid X] = 0$$

formaliza exatamente a ideia de que o erro contém apenas a parte não explicada do fenômeno.

3.3 Ortogonalidade entre erro e variáveis explicativas

Da propriedade da esperança condicional segue que

$$E[Xu] = 0.$$

Isso é verdade, pois como ambos são independentes na média, podemos escrever como $E[X]E[u]$, e como $E[u] = 0$, temos a formula acima

Substituindo

$$u = y - Xw,$$

obtemos

$$E[X(y - Xw)] = 0.$$

Expandindo:

$$E[Xy] - E[XX^T]w = 0.$$

Logo,

$$\boxed{E[XX^T]w = E[Xy]}$$

Esta é a versão **populacional** da Equação Normal.

3.4 Da população para a amostra

Até aqui trabalhamos com quantidades populacionais, isto é, esperanças teóricas que normalmente não conhecemos.

Na prática observamos apenas uma amostra de tamanho n . Assim, substituímos os momentos populacionais pelos seus análogos amostrais:

$$E[Xy] \approx \frac{1}{n}X^Ty,$$

e

$$E[XX^T] \approx \frac{1}{n}X^TX.$$

Substituindo na equação anterior:

$$\frac{1}{n}X^TX\hat{w} = \frac{1}{n}X^Ty.$$

Multiplicando ambos os lados por n :

$$X^TX\hat{w} = X^Ty.$$

Finalmente,

$$\boxed{\hat{w} = (X^TX)^{-1}X^Ty.}$$

4 Comparando as duas deduções

Bom, como viram, na dedução via esperança assumimos explicitamente algo sobre o erro, que ele deve ser independente das variáveis preditoras. Ao passo de que a princípio não assumimos nada sobre o erro quando deduzimos via otimização. Entretanto isso não é exatamente verdade

A ideia fundamental aqui é que Otimizar o Erro Quadrático e Garantir a Premissa de Ortogonalidade são, na verdade, duas faces da mesma moeda. Quando pedimos para um otimizador (como o Gradient Descent) minimizar a distância entre a previsão e o valor real, ele faz isso calculando derivadas. Relembrando, a formula do gradiente:

$$\frac{\partial}{\partial w} SSE(w) = -X^T y + X^T X w$$

E idendica a formula do erro pelo lado da esperança

$$E[Xu] = E[XY] - E[XX^T]w.$$

E nesse momento, o que fizemos com o gradiente na perspectiva da otimização? Igualamos a zero Na perspectiva da otimização, isso apenas nos diz que queremos que o erro seja o menor possível, e a princípio, parece que estamos assumindo apenas a condição fraca que a $E[u] = 0$. Porém agora que sabemos que o gradiente é igual ao valor esperado do erro, podemos ver alguma relações interessantes:

$$\begin{aligned}\frac{\partial}{\partial w} SSE(w) &= E[-Xu] \\ \frac{\partial}{\partial w} SSE(w) &= -X^T \hat{u}\end{aligned}$$

Onde $\hat{u}$ são os resíduos (pense nele como os erros concretos, que realmente aconteceram, e não o objeto teórico do erro) Considerando que igualamos $-X^T \hat{u}$ a 0, a única forma disso ser possível, é se X e $\hat{u}$ forem ortogonais, isso é, possuírem correlação igual a 0, e caso não saiba, a formula $X^T \hat{u}$ é exatamente a formula da covariância multivariada.

Abaixo há um gráfico interativo, onde plota uma regressão linear com duas variáveis preditoras X_1 , X_2 e uma terceira variável alvo y . Esse espaço vetorial das nossas variáveis nos permite visualizar como existe um espaço de erro pelo simples fato de as variáveis preditoras não conseguirem apontar para a variável alvo através de combinações lineares, dessa forma, podemos ver claramente que o erro é ortogonal as variáveis preditoras

Unable to display output for mime type(s): text/html

(a) Projeção Ortogonal

Unable to display output for mime type(s): text/html

(b)

Figure 4.1

Com isso podemos ver que na realidade, em ambos os casos estamos assumindo exatamente os mesmos pressupostos, apesar de no início não parecer o caso.

Um último detalhe interessante, como pudermos ver, não assumimos que o erro é gaussiano para chegar nesse resultado, acredito que muitas pessoas se confundam achando que a premissa de otimizar um modelo linear com SSE, ou melhor, via a formula normal pressupõem estritamente isso, o que não é verdade. Entretanto, acredito que essa confusão seja devido ao [Teorema de Gauss-Markov](#) que diz que caso o erro possua variância constante, nossa regressão linear é um BLUE (Best Linear Unbiased Estimator), e se assumirmos que todos os erros vem de uma mesma gaussiana, o erro possui variância constante.

Nota: Existe um outro teorema, chamado [Teorema de Rao-Blackwell](#), que segundo ele, caso o erro siga uma gaussiana, a formula normal não apenas nos garante um BLUE, como um BUE (Best Unbiased Estimator)